Harness de paris sportifs IA : structure du projet

Objectif

Construire un système en Python qui collecte des données sportives gratuites (football dont Ligue 1, et NBA), estime des probabilités, demande à des modèles d'IA d'analyser le contexte, puis enregistre des paris VIRTUELS pendant 2 semaines. À la fin, on mesure si le système bat le marché. Aucun argent réel n'est engagé dans cette phase.

Principes pour l'agent de code

- Langage : Python 3.11 ou plus récent.
- Base de données : SQLite (un seul fichier, zéro coût).
- Interface : Streamlit.
- Planification : un script lancé par cron ou par APScheduler, une fois par jour.
- Les clés API sont dans un fichier .env, jamais dans le code.
- Chaque appel API est mis en cache dans SQLite pour respecter les limites gratuites.
- Tout pari virtuel est enregistré AVANT le match, avec horodatage, et ne peut plus être modifié ensuite.

Arborescence des fichiers

- `betting_harness/`
  - `.env.example` : modèle des clés (ODDS_API_KEY, FOOTBALL_DATA_KEY, DEEPSEEK_API_KEY, JEV_API_KEY, GEMINI_API_KEY)
  - `requirements.txt`
  - `config.py` : sports actifs, ligues, limites de mise virtuelle, seuils
  - `db.py` : création du schéma SQLite et fonctions d'accès
  - `collectors/`
    - `football_data.py` : matchs, classements, historiques
    - `balldontlie_nba.py` : matchs et stats NBA
    - `odds.py` : cotes via The Odds API

    - `injuries_news.py` : blessures et actualités (optionnel au début)
  - `models/`
    - `stats_model.py` : modèle statistique de probabilités
    - `llm_analyst.py` : appel aux modèles d'IA pour le contexte
    - `jev_client.py` : appel à Jev si l'accès est obtenu
  - `decision/`
    - `value_bet.py` : calcul de la value et choix des paris virtuels
    - `bankroll.py` : gestion de la mise fictive
  - `tracking/`
    - `settle.py` : récupère les résultats et règle les paris
    - `metrics.py` : calcul des indicateurs de performance
  - `app.py` : interface Streamlit
  - `run_daily.py` : orchestre toute la chaîne chaque jour
  - `tests/`

Sources de données gratuites

- **football-data.org** : football, environ 12 compétitions dont la Ligue 1. Calendriers, résultats, classements. Clé gratuite par inscription.
- **balldontlie.io** : NBA, stats détaillées depuis 1979. Offre gratuite avec limite de requêtes.
- **TheSportsDB** : complément multi-sports gratuit.
- **The Odds API** : cotes de plusieurs bookmakers. Offre gratuite limitée en requêtes mensuelles. 1xBet n'est pas garanti, donc utiliser la cote moyenne du marché comme référence.
- Vérifier les limites exactes de chaque offre gratuite avant de coder, car elles changent.

Schéma de base de données

- `matches` : id, sport, ligue, date, équipe domicile, équipe extérieur, résultat
- `odds_snapshots` : match_id, bookmaker, marché, cote, horodatage
- `team_stats` : équipe, date, forme récente, buts, repos, etc.
- `predictions` : match_id, source (stats, deepseek, gemini, jev), probabilité, horodatage

- `virtual_bets` : id, match_id, marché, cote prise, mise fictive, probabilité estimée, value, date de placement, statut
- `results` : match_id, résultat final, date de règlement

Pipeline quotidien

1. **Collecte** : récupérer les matchs des prochaines 24 à 48 heures, les cotes et les stats récentes.
2. **Modèle statistique** : produire une probabilité par issue. Football : modèle de Poisson sur les buts, ou classement Elo. NBA : Elo ajusté (repos, domicile) ou régression simple.
3. **Analyse IA** : envoyer à DeepSeek et Gemini un résumé structuré (stats, cotes, blessures) et demander une probabilité et une justification en JSON strict. Ajouter Jev en troisième avis si accès obtenu, via son endpoint de questions typées (probabilité qu'une affirmation soit vraie).
4. **Fusion** : probabilité finale = moyenne pondérée du modèle statistique et des IA. Les poids sont configurables.
5. **Décision** : calculer la value = probabilité finale × cote − 1. Parier virtuellement seulement si la value dépasse un seuil (par exemple 5 %) et si les modèles sont globalement d'accord.
6. **Enregistrement** : insérer le pari virtuel avec toutes les données de la décision.
7. **Règlement** : le lendemain, récupérer les résultats et clôturer les paris.

Règles de mise virtuelle

- Bankroll fictive de départ, par exemple 1000 unités.
- Mise fixe de 1 % de la bankroll par pari (pas de martingale).
- Plafond de paris par jour pour éviter de diluer la qualité.

Indicateurs de performance

- ROI et profit en unités
- Taux de réussite
- **CLV (Closing Line Value)** : comparer la cote prise à la cote de clôture. C'est l'indicateur le plus fiable sur un petit échantillon.

- Score de Brier ou log-loss de chaque modèle : permet de dire lequel des modèles (stats, DeepSeek, Gemini, Jev) est le mieux calibré.
- Nombre total de paris (pour juger si l'échantillon est significatif).

Interface Streamlit

- Page 1 : paris du jour, avec probabilité de chaque modèle, cote, value, justification de l'IA.
- Page 2 : historique des paris virtuels et courbe de bankroll.
- Page 3 : comparaison des modèles (Brier, ROI, CLV).
- Bouton d'export CSV.

Ordre de construction pour l'agent de code

1. Créer le projet, la base SQLite et le fichier de config.
2. Coder les collecteurs football-data.org et balldontlie avec cache.
3. Coder le collecteur de cotes.
4. Coder le modèle statistique et le valider sur l'historique.
5. Coder le module d'analyse IA avec sortie JSON stricte et validation.
6. Coder la décision de value bet et l'enregistrement des paris virtuels.
7. Coder le règlement et les métriques.
8. Construire l'interface Streamlit.
9. Programmer l'exécution quotidienne et lancer les 2 semaines de test.

Points de vigilance

- Les modèles d'IA ne doivent pas calculer les probabilités de tête : le modèle statistique fournit la base, l'IA apporte le contexte.
- Toujours forcer une sortie JSON et rejeter toute réponse invalide.
- Deux semaines donnent un échantillon petit : ne pas tirer de conclusion définitive, surtout si le nombre de paris est inférieur à 100.
- Les cotes gratuites peuvent avoir du retard : enregistrer l'horodatage de chaque cote.
- Jev est en accès anticipé sur liste d'attente : prévoir le projet pour fonctionner sans lui.

- Rappel : les bookmakers intègrent déjà l'essentiel de l'information dans leurs cotes. Ce test sert à mesurer honnêtement, avant d'envisager de l'argent réel.